



INTITULÉ DU MODULE: INGÉNIERIE DE PROMPT

ENSEIGNANT: IMAD MOUHIB

2025/2026

Objectif:

- Programmation Informatique VS Intelligence Artificielle
- Présentation des concepts clés de l'IA générative
- Les modèles de langage (LLMs)
- Distinction entre l'IA symbolique et l'IA connexionniste.
- Prise en main d'un LLM [ChatGPT, Gemini, deepseek, perplexity]



INTELLIGENCE ARTIFICIELLE VS PROGRAMMATION INFORMATIQUE

1.Programmation informatique:

- **Approche** : Basée sur des algorithmes déterministes. Le développeur définit chaque étape logique. Par exemple, pour un programme qui calcule la moyenne, on lui donnerait les étapes exactes : "additionne tous les nombres, puis divise la somme par le nombre total de ces nombres."
- **Résultat** : Prévisible et constant. Pour les mêmes entrées, le programme générera toujours la même sortie. **Exemple** : Un programme pour un distributeur de billets.

INTELLIGENCE ARTIFICIELLE VS PROGRAMMATION INFORMATIQUE

2.Intelligence Artificielle:

- **Approche** : Basée sur des algorithmes d'apprentissage. L'IA est entraînée sur de grandes quantités de données pour qu'elle apprenne à reconnaître des schémas et à prendre des décisions.
- **Résultat** : Peut varier car le modèle évolue avec de nouvelles données. **Exemples** : Les systèmes de recommandation de Netflix/youtube

PRÉSENTATION DES CONCEPTS CLÉS DE L'IA GÉNÉRATIVE

Qu'est-ce que l'IA générative ?

- L'intelligence artificielle générative désigne des modèles et des algorithmes capables de créer de nouveaux contenus originaux, qu'il s'agisse de textes, d'images, de sons, de vidéos ou de code logiciel, en se basant sur l'analyse de données existantes

PRÉSENTATION DES CONCEPTS CLÉS DE L'IA GÉNÉRATIVE

Exemple d'IA Générative:

Pour le texte:

- **ChatGPT** : Un chatbot d'OpenAI, capable de générer du texte et de répondre à des questions.
- **Google Gemini**: (anciennement Bard) : Un concurrent de ChatGPT développé par Google pour converser et générer du texte.
- **Mistral AI** : Un modèle français qui propose des alternatives européennes, souvent en open source, aux modèles anglo-saxons.
- **Microsoft Copilot** : Intégré dans les applications Microsoft, il utilise une base similaire à ChatGPT

PRÉSENTATION DES CONCEPTS CLÉS DE L'IA GÉNÉRATIVE

Exemple d'IA Générative:

Pour les images

DALL-E : Permet de générer des images à partir de descriptions textuelles.

Midjourney : Une autre IA puissante pour la création d'images réalistes à partir de texte.

Stable Diffusion : Un modèle populaire pour produire des images de haute résolution.

Adobe Firefly : Permet de créer et modifier des conceptions graphiques avec des invites textuelles



PRÉSENTATION DES CONCEPTS CLÉS DE L'IA GÉNÉRATIVE

Exemple d'IA Générative:

Pour la vidéo

Sora : Un modèle d'OpenAI capable de générer des clips vidéo à partir de texte.

Google Veo : L'outil de génération de vidéo de Google DeepMind.

Runway AI Gen-4 : Un autre système capable de créer des vidéos à partir de descriptions textuelles.



PRÉSENTATION DES CONCEPTS CLÉS DE L'IA GÉNÉRATIVE

Exemple d'IA Générative:

Pour la musique

MusicLM : Capable de générer de nouvelles compositions musicales à partir de descriptions textuelles



PRÉSENTATION DES CONCEPTS CLÉS DE L'IA GÉNÉRATIVE

Comment fonctionne l'IA générative ?

- L'IA générative s'appuie sur des LLM **Large Language Model** pour apprendre les schémas et les relations dans un ensemble de données de contenus créés manuellement

Utilisateur



Envoie une requête (« prompt ») en langage naturel au modèle



ChatGPT

basé sur LLM, e.g gpt-3



LES MODÈLES DE LANGAGE (LLMS)

«LARGE LANGUAGE MODEL »

Définition:

- un LLM est un programme informatique nourri de suffisamment d'exemples pour être capable de reconnaître et d'interpréter le langage humain ou d'autres types de données complexes

Comment les modèles LLM sont-ils formés ?

1. **Collecte de données textuelles** : La formation d'un LLM commence par la collecte d'une grande quantité de données textuelles. Ces données peuvent provenir de livres, de sites Web, d'articles ou de plateformes de médias sociaux. L'objectif est de saisir la riche diversité du langage humain.
2. **Nettoyer les données** : Les données textuelles brutes sont ensuite rangées dans un processus appelé prétraitement. Cela inclut des tâches telles que la suppression des caractères indésirables, la décomposition du texte en parties plus petites appelées jetons et la mise en forme du tout dans un format avec lequel le modèle peut fonctionner.
3. **Fractionner les données** : Ensuite, les données propres sont divisées en deux ensembles. Un ensemble, les données d'entraînement, sera utilisé pour entraîner le modèle. L'autre ensemble, les données de validation, sera utilisé plus tard pour tester les performances du modèle.
4. **Configuration du modèle** : La structure du LLM, appelée architecture, est alors définie. Cela implique de sélectionner le type de réseau de neurones et de décider de divers paramètres, tels que le nombre de couches et d'unités cachées au sein du réseau.
5. **Entraînement du modèle** : La formation proprement dite commence maintenant. Le modèle LLM apprend en examinant les données de formation, en faisant des prédictions basées sur ce qu'il a appris jusqu'à présent, puis en ajustant ses paramètres internes pour réduire la différence entre ses prédictions et les données réelles.
6. **Vérification du modèle** : L'apprentissage du modèle LLM est vérifié à l'aide des données de validation. Cela permet de voir les performances du modèle et d'ajuster les paramètres du modèle pour de meilleures performances.

7. **Utilisation du modèle**: Après formation et évaluation, le modèle LLM est prêt à l'emploi. Il peut maintenant être intégré dans des applications ou des systèmes où il générera du texte basé sur les nouvelles entrées qui lui sont données.
8. **Amélioration du modèle** : Enfin, il y a toujours place à l'amélioration. Le modèle LLM peut être affiné au fil du temps, en utilisant des données mises à jour ou en ajustant les paramètres en fonction des commentaires et de l'utilisation dans le monde réel.

COMMENT L'IA GÉNÉRATIVE TRAITE NOTRE PROMPT?

1. Saisie du Prompt
2. Découpage en Morceaux (Tokenization)
3. Traduction en Langage Numérique (Embedding)
4. Analyse et Compréhension
5. Choix du Prochain Mot (Prédiction)
6. Construction Mot par Mot (Génération Itérative)
7. Résultat Final

IA SYMBOLIQUE, IA CONNEXIONNISTE ET IA HYBRIDE



L'IA symbolique

Expertise humaine dans une machine
Règles de type “**si X alors Y**”




Modélisation manuelle
Manque de flexibilité



L'IA connexionniste

Réseaux de **neurones** et **deeplearning**
Système programmé pour **apprendre**
Crée des associations lui même entre
entrées et sorties



Probabiliste et empirique =
manque d'explicabilité des
algorithmes

Les fondements techniques des LLMs

Où « vivent » les connaissances d'un LLM ?

Le stockage du LLM existent physiquement sous forme numérique et sont stockés sur des supports matériels dédiés à la mémoire vive (RAM/VRAM) ou au stockage permanent (serveur cloud)



Les fondements techniques des LLMs : « les Tokens, les embeddings et les modèles de transformateurs »

1. Les Tokens : l'unité de base du langage pour un modèle

Les Tokens sont les plus petites unités de texte que les modèles de langage comprennent et traitent.

Un Token peut représenter :

- un mot entier (maison)
- une partie de mot (ingéni + eure)
- un symbole (;, ?, !)
- ou même un espace ()



Les fondements techniques des LLMs : « les Tokens, les embeddings et les modèles de transformateurs »

1. Les Tokens : l'unité de base du langage pour un modèle

Exemple :

Prenons la phrase :

“Les LLMs comprennent le langage humain.”

Elle peut être découpée en tokens comme :

["Les", " L", "LM", "s", " compr", "ennent", " le", " langage", " humain", "."]



Les fondements techniques des LLMs : « les Tokens, les embeddings et les modèles de transformateurs »

1. Les Tokens : l'unité de base du langage pour un modèle

Un grand modèle comme GPT ou Claude **ne comprend pas** directement les mots, mais cette séquence de Tokens, convertie ensuite en nombres.

Texte → [Découpage en Tokens] → [Représentation numérique]

"Bonjour le monde" → ["Bonjour", " le", " monde"] → [2456, 112, 907]



Les fondements techniques des LLMs : « les Tokens, les embeddings et les modèles de transformateurs »

2. Les Embeddings : transformer les mots en vecteurs

Un Embedding est une représentation numérique d'un mot dans un **espace vectoriel**, Cela permet au modèle de comprendre la signification et les relations sémantiques entre les mots

Exemple :

- “roi” $\rightarrow$ [0.25, 0.81, -0.34, ...]
- “reine” $\rightarrow$ [0.27, 0.83, -0.32, ...]
- “voiture” $\rightarrow$ [-0.10, 0.55, 0.02, ...]

Remarque: roi et reine sont proches, tandis que voiture est loin



Les fondements techniques des LLMs :

« les Tokens, les Embeddings et les modèles de transformateurs »

3. Les Modèles de Transformateurs : le Cerveau des LLMs

Un modèle de transformateur est un type d'architecture de modèle utilisé dans les LLMs, il permet de comprendre le langage et générer du texte en capturant les relations entre les mots, peu importe leur distance dans la phrase.

Exemple :

dans la phrase “Le chat mange **sa** nourriture”, le mot “**sa**” se réfère à “**chat**”.



Les règles d'or de l'ingénierie de prompt « CCRO FCI »

Clarté → un prompt flou donne une réponse floue

Exemple : « Parle-moi du marketing » → trop vague

Contexte → toujours situer la demande

Exemple : « Explique le marketing digital à un étudiant de 1ère année »

Les règles d'or de l'ingénierie de prompt

Rôle → définir qui est l'IA

Exemple : « Agis comme un expert en communication digitale »

Objectif précis → indiquer ce qu'on attend de la réponse

Exemple : « Rédige un plan de cours en 5 parties.. »



Les règles d'or de l'ingénierie de prompt

Format attendu → spécifier la forme de la réponse

Exemple : « Présente sous forme de tableau » ou « Donne un plan structuré »

Contraintes → ajouter des limites ou critères

Exemple : « 150 mots maximum, langage formel »

Itération → l'ingénierie de prompt est un dialogue, pas une seule tentative

Les règles d'or de l'ingénierie de prompt

Format attendu → spécifier la forme de la réponse

Exemple : « Présente sous forme de tableau » ou « Donne un plan structuré »

Contraintes → ajouter des limites ou critères

Exemple : « 150 mots maximum, langage formel »

Itération → l'ingénierie de prompt est un dialogue, pas une seule tentative



Zero-Shot Prompting et Few-Shot Prompting.

Ce sont deux méthodes d'interaction avec les modèles de langage (LLM) selon le nombre d'exemples fourni dans un prompt.

1. Zero-shot prompting (ZSP):

On donne une instruction directe au modèle sans aucun exemple préalable. On fait confiance à ses connaissances internes pour comprendre notre demande.

Structure : [Instruction claire + contexte + format attendu]

Exemple : « Résume ce texte en trois phrases simples. »



Zero-Shot Prompting et Few-Shot Prompting.

Avantages :

- Rapide et simple à rédiger
- Bon pour les tâches générales que le modèle connaît déjà
- Idéal pour tester la compréhension "générale" du LLM

Limites :

- Moins précis si la tâche est complexe ou spécifique
- Le ton, le style ou le format peuvent être mal interprétés

En bref: Zero-shot = pas d'exemple → le modèle devine la méthode.

Zero-Shot Prompting et Few-Shot Prompting.

2. Few-shot prompting (FSP)

On donne quelques exemples concrets dans le prompt avant la tâche principale. Le modèle apprend le style, la structure ou la logique à reproduire.

Structure : [Exemple 1] [Exemple 2] ... [Nouvelle demande à traiter]

Exemple : Exemple 1 :
Q : Quelle est la capitale du Maroc ?
R : Rabat.

Exemple 2 :
Q : Quelle est la capitale de la France ?
R : Paris.

Q : Quelle est la capitale de l'Italie ?
(Réponse attendue : Rome)

Zero-Shot Prompting et Few-Shot Prompting.

Avantages :

- Plus de cohérence et de contrôle sur la réponse
- Permet d'enseigner le format ou le ton attendu
- Très utile pour les tâches spécialisées ou créatives (résumés, email marketing, évaluation, etc.)

Limites :

- Plus long à rédiger
- Risque de "biais" si les exemples sont mal choisis

En bref: Few-shot = quelques exemples → le modèle imite le schéma.